

## **BIOMARCADORES EN DEPRESIÓN CON SEÑALES DE ELECTROENCEFALOGRAFÍA: ARTÍCULO DE REVISIÓN**

Jimenez Medina Dominick M.<sup>1</sup>, Rocha Páramo Joselyn<sup>2</sup>, Ruelas Estrada Edwin A.<sup>3</sup>

### **Resumen**

La depresión es uno de los trastornos mentales con mayor prevalencia a nivel mundial, afectando a millones de personas. El electroencefalograma (EEG) es una herramienta utilizada para el diagnóstico de dicho trastorno, así como para identificar el estadio y respuesta ante tratamientos, un EEG consta generalmente de electrodos colocados en el cuero cabelludo los cuales comparan la actividad eléctrica entre regiones cerebrales.

En este artículo de revisión se busca recopilar información reciente acerca de biomarcadores en depresión; para esto se seleccionaron 70 artículos en bases de datos científicas y se hizo un análisis de los principales métodos y resultados descritos.

Los artículos muestran una clara tendencia al uso de inteligencia artificial como deep y machine learning para apoyar a la clasificación entre sujetos control y sujetos con depresión; mientras que en el apartado de resultados numerosos estudios reportan una asimetría entre hemisferios cerebrales, alteraciones en ondas alfa y delta, además de una hiperactividad cerebral y una conectividad funcional aleatoria.

**Palabras Clave:** Electroencefalograma, Depresión, Salud mental

### **Abstract**

Depression is one of the most prevalent mental disorders worldwide, affecting millions of people. The electroencephalogram (EEG) is a tool used for the diagnosis of this disorder, as well as for identifying the stage and response to treatments. An EEG generally consists of electrodes placed on the scalp that compare electrical activity between brain regions.

This review article aims to gather recent information on biomarkers in depression. For this purpose, 70 articles from scientific databases were selected and an analysis of the main methods and results described was conducted.

The articles show a clear trend towards the use of artificial intelligence, such as deep and machine learning, to aid in the classification between control subjects and subjects with depression. In terms of results, numerous studies report asymmetry between brain hemispheres, alterations in alpha and delta waves, as well as hyperactivity in the brain and random functional connectivity

**Keywords:** Electroencephalography, depression, mental health

---

<sup>1</sup> Egresado de la Carrera de Ingeniería Biomédica del Centro Universitario de Ciencias Exactas e Ingenierías de la Universidad de Guadalajara.

<sup>2</sup> Estudiante de ELE 7mo Sem. Universidad Autónoma de Baja California, Sede Mexicali.

<sup>3</sup> Estudiante de 7mo semestre en ingeniería biomédica. Universidad de Sonora, campus Hermosillo.

Autor para correspondencia: [dominickmateo1404@gmail.com](mailto:dominickmateo1404@gmail.com), [rocha.joselyn@uabc.edu.mx](mailto:rocha.joselyn@uabc.edu.mx), [edwinalain@live.com.mx](mailto:edwinalain@live.com.mx)

## **1. Introducción**

El trastorno depresivo, comúnmente conocido como depresión, es una condición mental que afecta significativamente el comportamiento y el estado de ánimo de los individuos, influyendo negativamente en sus relaciones sociales y en sus desempeños escolares o laborales (OPS, 2023). La aparición de este trastorno puede atribuirse a diversas causas, incluyendo pérdidas personales, abusos y eventos estresantes o traumáticos.

A nivel mundial, se estima que aproximadamente 280 millones de personas sufren de depresión, lo que representa el 3.8 % de la población total (OMS, 2023). Este trastorno psiquiátrico es uno de los más estudiados debido a su alta prevalencia y al impacto significativo que tiene en la calidad de vida de quienes lo padecen. Los afectados pueden experimentar una variedad de síntomas, tales como ideación suicida, comportamientos autolesivos, baja autoestima, desmotivación y tristeza profunda.

La detección temprana y el diagnóstico preciso de la depresión son fundamentales para abordar eficazmente este trastorno. Entre los métodos utilizados, el electroencefalograma (EEG) ha ganado atención debido a su capacidad para medir la actividad eléctrica cerebral a través de electrodos colocados sobre el cuero cabelludo. Al analizar las diferencias de potencial entre diversas regiones cerebrales, es posible identificar áreas con mayor o menor actividad, apoyando así el diagnóstico de distintas neuropatologías, incluida la depresión.

La búsqueda de biomarcadores para la depresión representa un área de investigación en rápido crecimiento. Los biomarcadores son indicadores biológicos medibles objetivamente que reflejan procesos patológicos o respuestas a intervenciones terapéuticas. En el contexto de la depresión, estos biomarcadores pueden proporcionar información crucial sobre la fisiopatología del trastorno, mejorar la precisión del diagnóstico y facilitar la personalización de los tratamientos.

El EEG se destaca como una herramienta prometedora y rentable para predecir la respuesta del cerebro, al capturar la actividad cerebral y brindar la posibilidad de realizar un análisis de los patrones eléctricos asociados con estados emocionales y cognitivos. Estudios recientes [5][8][12][17][31] han explorado diversas características del EEG, como la conectividad funcional y los ritmos cerebrales, en busca de patrones específicos que puedan servir como biomarcadores de la depresión.

Los avances tecnológicos en el procesamiento de señales EEG y el uso de técnicas de aprendizaje automático están mejorando la capacidad para identificar estos biomarcadores con mayor precisión y fiabilidad.

En este artículo, proporcionamos una breve visión sobre el estudio de la depresión con señales de EEG y métodos para identificar biomarcadores en estas.

## **2. Planteamiento del problema**

La depresión es un trastorno mental complejo y multifacético que afecta a millones de personas en todo el mundo, representando una carga significativa tanto para los individuos como para la sociedad. A pesar de los avances en el tratamiento y la gestión de la depresión, el diagnóstico preciso y la personalización de los tratamientos siguen siendo desafíos importantes. En este contexto, la búsqueda de biomarcadores específicos para la depresión ha emergido como una estrategia crucial para mejorar la comprensión, el diagnóstico y el tratamiento de este trastorno.

Este artículo de revisión tiene como objetivo contrastar los resultados obtenidos en materia de EEG y biomarcadores en depresión e incitar a la comunidad científica a seguir investigando en el tema.

### 3. Metodología

#### 3.1 Elaboración de cadena de búsqueda

Se realizó una cadena de búsqueda para conocer las investigaciones recientes con señales de EEG y depresión. La cadena de búsqueda incluye las palabras: “depression”, “mental health”, “EEG” y “electroencephalography”.

(EEG V electroencephalography)  $\wedge$   
depression V mental health  $\neg$  Alzheimer,  
schizophrenia, parkinson, etc.

Figura 1. Cadena de búsqueda para la selección de artículos

#### 3.2 Criterios de inclusion y exclusion

La cadena de búsqueda fue utilizada en las bases de datos Scopus, PubMed, ScienceDirect además del buscador Google Scholar. Se incluyeron artículos en el idioma inglés y español, y no hubo distinción en cuanto a ubicación geográfica.

A su vez, se excluyeron todos aquellos artículos que incluían en su investigación otros trastornos neurológicos además de depresión tales como esquizofrenia, enfermedad de Alzheimer, entre otros; o con una antigüedad mayor a 5 años (>2019), filtrando un total de 70 artículos que posteriormente fueron organizados en tablas para contrastar la metodología y los resultados obtenidos en cada uno de ellos.

### 4. Revisión literaria

Los biomarcadores son indicadores biológicos que pueden ser medidos objetivamente y permiten obtener información sobre procesos fisiopatológicos, estados de enfermedad o respuestas a intervenciones terapéuticas.

Con base en los artículos revisados, se identificaron aspectos potenciales en el uso de biomarcadores en el estudio de la depresión, algunos de ellos:

**1. Mejorar la precisión del diagnóstico:** actualmente, el diagnóstico de la depresión se basa principalmente en evaluaciones clínicas y cuestionarios subjetivos. Los biomarcadores ofrecen una medida objetiva que complementa dichos métodos, reduciendo la posibilidad de diagnósticos erróneos.

**2. Facilitar la personalización del tratamiento:** la identificación de biomarcadores específicos asociados con los subtipos de depresión o respuestas particulares al tratamiento, permite desarrollar estrategias terapéuticas centradas en el paciente, siendo más efectivas y mejorando los resultados clínicos.

**3. Comprender la fisiopatología de la depresión:** la utilización de biomarcadores en el estudio de la depresión puede ampliar la perspectiva sobre los mecanismos biológicos de este trastorno, conduciendo al desarrollo de intervenciones terapéuticas novedosas y un mejor entendimiento de la enfermedad.

Como se mencionó, en la actualidad el electroencefalograma se considera una herramienta potencialmente diagnóstica de la depresión. Esta es una técnica no invasiva que mide la actividad eléctrica del cerebro a través de electrodos colocados en el cuero cabelludo; ofrece varias ventajas en la búsqueda de biomarcadores para la depresión, como la captura de actividad cerebral en tiempo real, una alta resolución temporal e identificación de patrones específicos.

En los últimos años, la investigación sobre biomarcadores de EEG para la depresión ha avanzado significativamente, destacando entre estos avances:

**1. Procesamiento avanzado de señales:** el desarrollo de técnicas avanzadas de procesamiento de señales permiten el análisis detallado de los

datos de EEG, identificando características específicas que pueden diferenciar entre individuos con y sin depresión. (Medina B, Sierra E, Ulloa A, 2018)

**2. Aprendizaje automático:** el uso de algoritmos de aprendizaje automático ha mejorado la capacidad para detectar patrones complejos en los datos de EEG, aumentando la precisión y fiabilidad en la identificación de biomarcadores. (Hewlett Packard Enterprise, 2024)

**3. Conectividad cerebral:** diversas investigaciones han estudiado la conectividad funcional, identificando alteraciones en la comunicación neural que podrían estar asociadas con la depresión. (Martijn P, Hilleke E, 2011)

La identificación de biomarcadores de EEG tiene el potencial de transformar el manejo clínico de la depresión. Estos biomarcadores pueden mejorar la precisión del diagnóstico, permitir la personalización de los tratamientos y ofrecer nuevas perspectivas sobre la fisiopatología del trastorno. A medida que la tecnología y las metodologías continúan avanzando, es probable que los biomarcadores de EEG se integren cada vez más en la práctica clínica, llevando a mejoras significativas en el tratamiento y la gestión de la depresión.

#### **4.1. Principales métodos**

A continuación, se describen algunos de los métodos más destacados utilizados en la identificación de patrones relacionados con la depresión:

##### **Máquinas de Vectores de Soporte (SVM) [1]**

Las SVM son una técnica de aprendizaje supervisado utilizada para clasificación y regresión. En el contexto de EEG y depresión, se han empleado para clasificar entre sujetos con y sin depresión, aprovechando su capacidad para manejar datos de alta dimensionalidad y encontrar el hiperplano óptimo que separa las diferentes clases.

##### **Bosques Aleatorios [1]**

Este método de aprendizaje supervisado se basa en la construcción de múltiples árboles de decisión. Los bosques aleatorios son robustos frente al sobreajuste y pueden manejar datos ruidosos, lo que los hace adecuados para analizar señales de EEG, donde pueden identificar características importantes para la clasificación de la depresión.

##### **Potenciación del Gradiente [1]**

El algoritmo de potenciación del gradiente combina varios modelos débiles para crear un modelo fuerte. En el análisis de EEG, este método ha demostrado ser eficaz para mejorar la precisión de la clasificación y la detección de patrones relacionados con la depresión al iterar y ajustar los errores de predicción.

##### **Convolución Espacio-Temporal [27]**

Esta técnica combina la información espacial y temporal de las señales de EEG. Se han utilizado modelos convolucionales para capturar la dinámica temporal de las señales y la distribución espacial de los electrodos, proporcionando una visión integral de los cambios asociados con la depresión.

##### **Deep Learning y Transfer Learning [15][19][25][66]**

El aprendizaje profundo, incluyendo las redes neuronales profundas, ha sido ampliamente utilizado para analizar EEG debido a su capacidad para aprender representaciones complejas de los datos. El transfer learning, o aprendizaje por transferencia, permite aplicar conocimientos adquiridos en un dominio a otro, facilitando la identificación de biomarcadores en conjuntos de datos de EEG más pequeños o específicos.

##### **Análisis de Conectividad Funcional (PLI) [9]**

El Índice de Fase de Sincronización (PLI) es una medida de conectividad funcional que evalúa la sincronización de fase entre diferentes regiones

cerebrales. Este análisis puede revelar alteraciones en la conectividad cerebral asociadas con la depresión, proporcionando información sobre las interacciones funcionales entre distintas áreas del cerebro.

### **Redes Neuronales Convolucionales (CNN) [4][12][16][17][18][30][55]**

Las CNN son especialmente útiles para el análisis de datos espaciales y han sido aplicadas a las señales de EEG para extraer características relevantes y realizar clasificaciones precisas. Su capacidad para aprender patrones espaciales complejos las hace ideales para la identificación de biomarcadores de depresión.

### **Support Vector Regressor [13]**

El regressor de vectores de soporte se utiliza para problemas de regresión, proporcionando estimaciones continuas. En el contexto de EEG y depresión, puede predecir la severidad de los síntomas depresivos basándose en características extraídas de las señales.

### **Redes LSTM (Long Short-Term Memory) [17][19]**

Las redes LSTM son un tipo de red neuronal recurrente diseñada para aprender dependencias a largo plazo. Estas redes han sido aplicadas a señales de EEG para capturar la dinámica temporal compleja que puede estar asociada con la depresión.

### **Modelos Híbridos CNN-LSTM [22][24]**

La combinación de CNN y LSTM permite aprovechar las fortalezas de ambas arquitecturas: las CNN para la extracción de características espaciales y las LSTM para el análisis temporal. Esta combinación ha mostrado ser efectiva para el análisis de señales de EEG en la búsqueda de biomarcadores de depresión.

### **Coherencia de Wavelet en EEG [28]**

La coherencia de wavelet mide la coherencia entre dos señales en el dominio tiempo-frecuencia. Esta técnica permite analizar cómo varía la coherencia entre diferentes regiones cerebrales a lo largo del tiempo, proporcionando información valiosa sobre los patrones de conectividad en sujetos con depresión.

### **Correlación [26][33][70]**

El análisis de correlación examina la relación lineal entre diferentes señales de EEG. Este método puede identificar regiones cerebrales cuya actividad está sincronizada y cómo estas relaciones pueden cambiar en presencia de depresión.

### **Entropía de Renyi [51]**

La entropía de Renyi es una medida de la complejidad de las señales de EEG. Al evaluar la entropía de las señales, se pueden identificar cambios en la complejidad cerebral asociados con la depresión, ofreciendo una perspectiva cuantitativa sobre las alteraciones en la dinámica cerebral.

## **4.2 Principales resultados**

En los últimos años, la investigación sobre biomarcadores de depresión en señales de EEG ha revelado una serie de hallazgos significativos que mejoran nuestra comprensión de esta condición. A continuación, se presentan los principales resultados de los artículos revisados:

Las diferencias en las ondas alfa y beta han sido uno de los hallazgos más consistentes. [1] Se ha observado que las señales en la corteza frontal y parieto-occipital del hemisferio derecho muestran diferencias significativas entre pacientes con depresión y sujetos sanos.[5][56] Estas diferencias también se extienden a las conexiones intra e interhemisféricas, [8][9][26][69] sugiriendo una disfunción en el hemisferio izquierdo en pacientes con depresión. [9][17]

La baja síntesis de serotonina en pacientes con depresión es un factor crucial que se correlaciona con la disfunción observada en las señales de EEG [10]. Además, se ha demostrado que el método de EEG en estado de reposo (resting state EEG) es más eficaz que el EEG basado en tareas (task based EEG) para identificar biomarcadores de depresión. [15]

Otro hallazgo importante es el de una mayor actividad en la corteza frontal en pacientes con depresión [16]. Además, se ha visto que la depresión también afecta la región temporal, especialmente en las ondas theta y alfa [18].

Se ha observado una asimetría interhemisférica en la banda alfa en pacientes con depresión, especialmente en los electrodos C5-C6. A su vez, la potencia en la región interhemisférica es mayor en pacientes con depresión, mostrando una mayor conectividad cerebral. [26]

La depresión está asociada con una hiperactivación de la corteza prefrontal derecha. Los pacientes con depresión presentan una menor potencia en los potenciales relacionados con eventos (event-related potentials) y muestran una mayor coherencia cerebral, lo que sugiere una configuración cerebral más aleatoria [31]. Además, se observan alteraciones en las oscilaciones de las bandas beta y gamma, particularmente en la corteza prefrontal [36], y en las bandas de baja frecuencia, especialmente en la delta [39].

Se ha reportado un aumento en el coeficiente de agrupamiento y en la eficiencia local en las bandas delta y theta, lo que indica una mayor integración funcional a nivel local en estas frecuencias [48]. Las áreas corticales en las regiones frontal, central y temporal, que comprenden las bandas alfa 2-beta y alfa 2-gamma 1, experimentan interrupciones durante el estado de depresión [65].

## **5. Caso de estudio**

Paralelo a la revisión bibliográfica se realizaron una serie de experimentos con el objetivo de generar resultados propios en la búsqueda de biomarcadores.

### **5.2 Objetivos y formulación de hipótesis**

#### ***Objetivo General:***

Identificar y validar biomarcadores específicos de depresión mediante el análisis de señales de electroencefalografía (EEG), con el fin de mejorar el diagnóstico y la personalización de tratamientos para esta condición.

#### ***Objetivos Específicos:***

1. Analizar las características de los ritmos cerebrales (alfa, beta, theta, delta) en individuos con y sin depresión utilizando técnicas de EEG.
2. Evaluar la coherencia y conectividad funcional entre diferentes regiones cerebrales en pacientes diagnosticados con depresión, comparándolos con individuos sanos.

#### ***Hipótesis:***

1. Los individuos con depresión presentan alteraciones significativas en los ritmos cerebrales, tales como disminución de la actividad alfa y aumento de la actividad beta en comparación con individuos sanos.
2. La coherencia y conectividad funcional entre regiones cerebrales, especialmente en los circuitos fronto-límbicos y fronto-parietales, se encuentran significativamente alteradas en pacientes con depresión en comparación con los individuos sanos.

### **5.2 Descripción de sujetos y adquisición de las señales**

Para el análisis se utilizaron dos señales de EEG, la señal de estudio obtenida de un paciente bajo tratamiento psicológico con un diagnóstico

sugere de depresión, y una señal control obtenida de una persona aparentemente sana. La señal control fue adquirida en el Laboratorio de Neurofisiología de la Universidad Autónoma de Manizales, Colombia; mediante un Electroencefalógrafo Easy III Cadwell siguiendo el protocolo 10 - 20 con 18 canales, con énfasis en la correcta colocación de los electrodos y el mantenimiento de una impedancia adecuada.

El método utilizado para la obtención de la señal control fue el método Resting State (Estado de Reposo), compuesto por un periodo de 4 minutos con ojos cerrados y 4 minutos con ojos abiertos.

### 5.3 Procesamiento de las señales

#### *Procesamiento en MATLAB:*

Se desarrollaron scripts para la importación y preprocesamiento de los datos de EEG. Inicialmente, se aplicaron filtros pasa banda, con el fin de eliminar señales no deseadas y centrar la señal en el rango de frecuencias de interés. Posteriormente, se utilizó la paquetería EEGLAB para implementar el Análisis de Componentes Independientes (ICA), que permitió identificar y eliminar artefactos provocados por actividades eléctricas cardíacas, oculares y musculares.

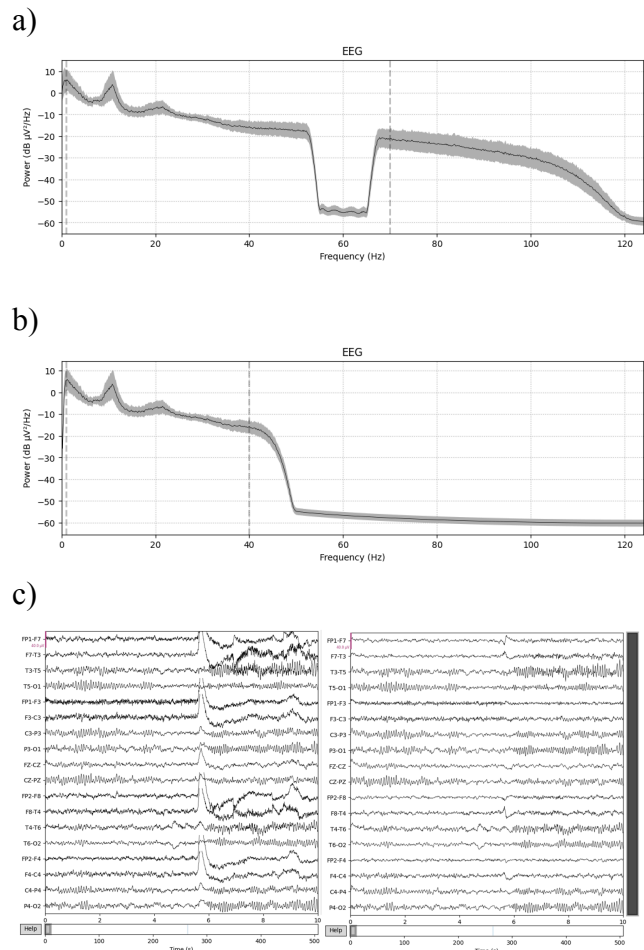
#### *Procesamiento en Python:*

El procesamiento de los datos de EEG se llevó a cabo utilizando la librería MNE. Al igual que en MATLAB, los datos fueron importados y se aplicaron filtros pasa banda para asegurar la consistencia en el preprocesamiento. La eliminación de artefactos se logró mediante el método ICA disponible en MNE, garantizando la limpieza de la señal EEG.

#### 5.3.1 Filtrado de la señal

Para ambas señales se incluyó un filtro pasa banda con frecuencias de corte en 1 y 40 Hz,

centrando la señal en el rango de frecuencias de nuestro interés y eliminando algunas señales de ruido.

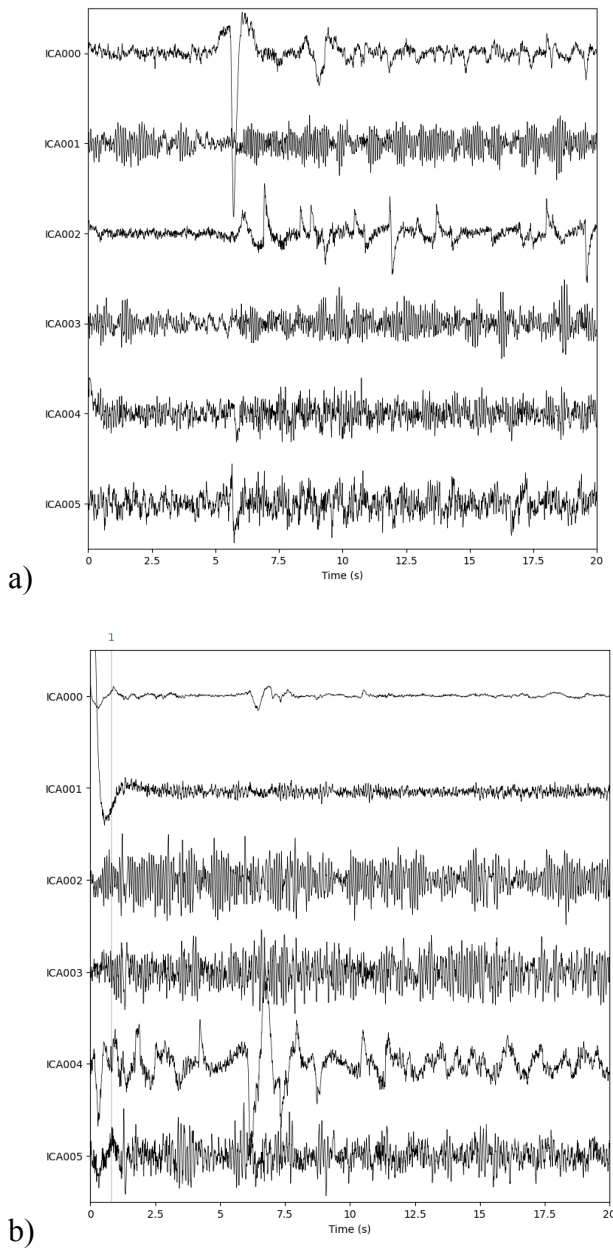


**Figura 2.** a) Espectrograma original de la señal control. b) Espectrograma de la señal control después del filtro pasa banda. c) Resultado procesamiento de señales, lado izquierdo: Señal control sin procesar, lado derecho: Señal control procesada

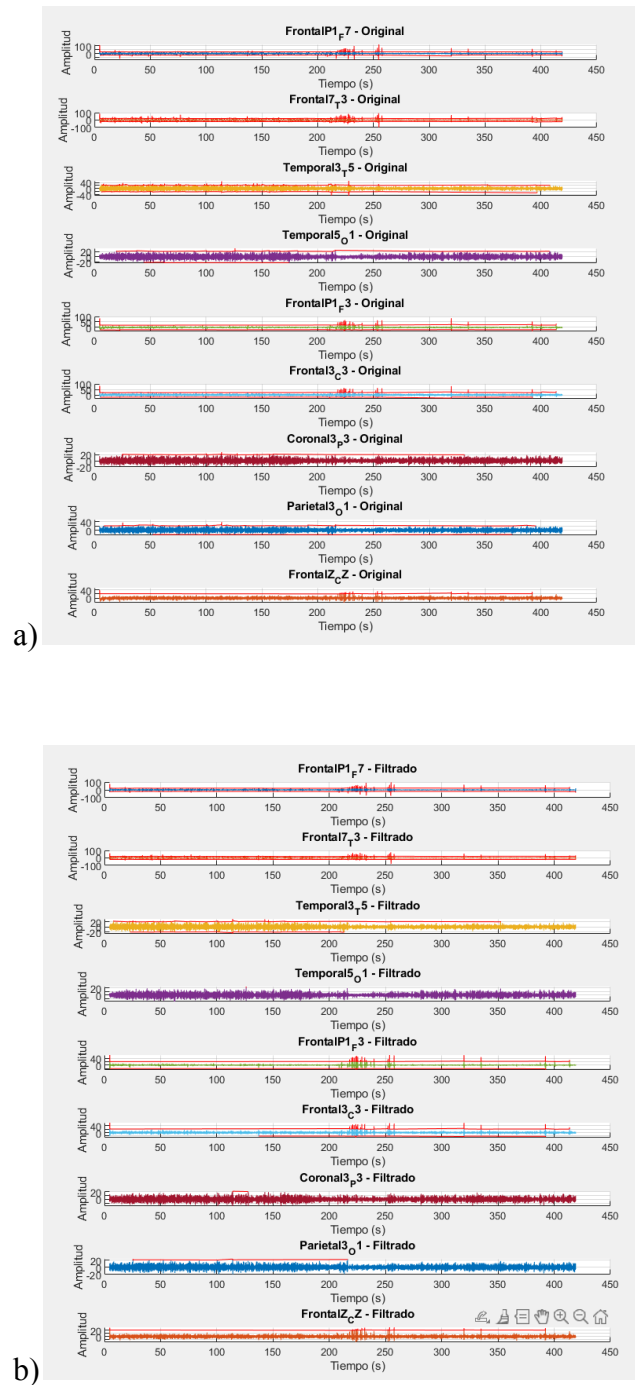
#### 5.3.2 Eliminación de artefactos

Posterior al filtrado, se identificaron diferentes artefactos, principalmente ocasionados por la actividad eléctrica cardíaca, ocular y muscular. Debido a que los electrodos de un EEG están diseñados para ser extremadamente sensibles a la actividad eléctrica, es muy probable que las señales mencionadas anteriormente interfieran con nuestra señal deseada. Para la eliminación de estos artefactos se utilizó el método ICA (Independent Component Analysis).

### 5.3.2.1 Procesamiento de señal en sujeto sano



**Figura 3.** Análisis de componentes en la señal control, a) se identificó el componente 0 y 2 como señales de ruido; b) se identificó el componente 0, 1 y 4 como señales de ruido.




**Figura 4.** a) Análisis de la señal sin filtro de sujeto sano b) Análisis de la señal filtrada de sujeto sano en Matlab (EEGLAB,2024) separados por lóbulos cerebrales, con característica en color rojo que marca los picos de frecuencia más altos de las ondas Alpha y Beta .

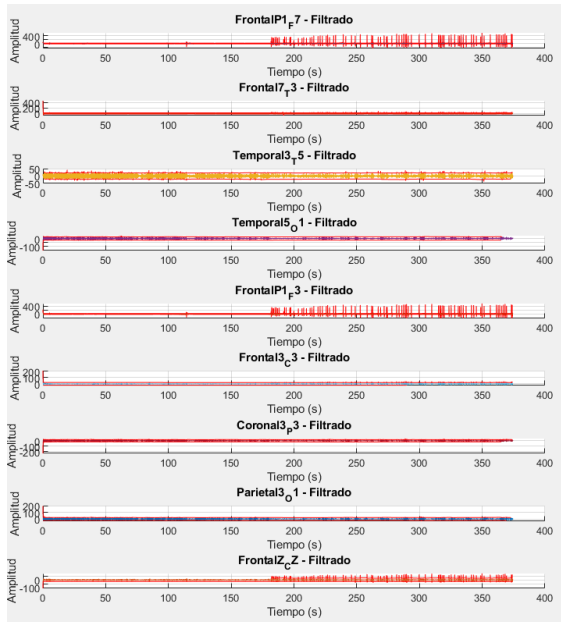


### 5.3.2.2 Procesamiento de señal en sujeto con depresión

a)



b)



**Figura 5.** a) Análisis de la señal sin filtro del sujeto con depresión  
b) Análisis de la señal de sujeto con depresión en Matlab (EEGLAB,2024) separados por lóbulos cerebrales, con característica en color rojo que marca los picos de frecuencia más altos de las ondas Alpha y Beta .

### 5.4 Análisis de conectividad funcional


La conectividad funcional se refiere a la correlación temporal de la actividad eléctrica medida en diferentes regiones del cerebro. En este caso, es útil para evaluar cual es el funcionamiento del cerebro con depresión a comparación de un cerebro sano.

El análisis se realizó con el método wPLI. El PLI es una medida de la consistencia de los desfases entre las señales de dos regiones del cerebro; mide la asimetría de las diferencias de fase entre dos señales, lo que ayuda a determinar la direccionalidad y la causalidad de las interacciones entre las regiones cerebrales. El wPLI es una versión ponderada del PLI, el cual también toma en cuenta la magnitud del desfase, proporcionando una medida más robusta y sensible de la conectividad.


Un valor de wPLI cercano a 1 indica una conectividad fuerte y consistente, mientras que un valor cercano a 0 indica poca o ninguna conectividad.

#### 5.4.1 Conectividad funcional en sujeto control

En el caso del sujeto control, se observó una gran conectividad en el rango de frecuencias correspondientes a las ondas alfa y delta, relacionadas con un estado de relajación mental y física; en comparación con el resto de bandas relacionadas con mayor actividad cerebral, hay una conectividad visiblemente menor, concordando con lo esperado gracias al método Resting State, donde el sujeto se encuentra en reposo sin presencia de estímulos externos.




**Figura 6.** Análisis de conectividad funcional de la señal control usando el método wPLI




**Figura 7.** Análisis de conectividad funcional de la señal de sujeto sano usando MATLAB (EEGLAB)

### 5.4.2 Conectividad funcional en sujeto con depresión

En la señal del sujeto con depresión, se observa una alta conectividad en todas las bandas, especialmente en las ondas delta.



**Figura 8.** Análisis de conectividad funcional de la señal del sujeto con depresión usando el método wPLI



**Figura 9.** Análisis de conectividad funcional de la señal de sujeto sano usando MATLAB (EEGLAB)

En algunos estudios se ha visto que los pacientes con depresión presentan una estabilidad y una sincronización fuera de los patrones de actividad cerebral normales. En ellos se ha mostrado que en cuanto a la conectividad funcional neuronal, los pacientes con depresión mayor presentan un incremento en la conectividad general y una disminución en las conexiones específicas del cerebro. [37]

## 6. Conclusiones

De acuerdo a la bibliografía revisada y el

experimento realizado, los sujetos con depresión muestran alteraciones en todas las bandas cerebrales, con un énfasis particular en las ondas alfa y delta, además de exhibir diferencias en las conexiones intra e interhemisféricas, así como una conectividad general notablemente mayor.

Los resultados demuestran que la electroencefalografía podría ser viable en el diagnóstico y tratamiento de la depresión. Durante el experimento, la comparación entre los dos sujetos de prueba reveló una mayor conectividad funcional en las ondas alfa y delta, mostrando cambios significativos en individuos con depresión. A su vez, se encontraron diferencias notables en los ritmos cerebrales, así como en la coherencia y conectividad funcional entre individuos con depresión y sujetos control, relacionándose con la severidad de los síntomas depresivos.

Además, en la mayoría de casos la implementación de algoritmos de aprendizaje automático permitió una clasificación precisa de individuos con y sin depresión. Estos hallazgos respaldan el posible uso de biomarcadores de EEG no solo para diagnosticar la depresión, sino también para monitorear su progresión y respuesta al tratamiento.

Sin embargo, estos resultados no son suficientes para denotar un biomarcador específico para depresión, actualmente es importante continuar con la investigación para garantizar una herramienta diagnóstica viable y eficaz para este trastorno mental.

## 7. Referencias

- [1] Greig, C. V. (2022). Apoyo al diagnóstico de depresión mediante análisis de señales de EEG y herramientas de aprendizaje automatizado. Tesis de Grado de Magíster. Universidad de Concepción.
- [2] Álvarez, F. J., Cardona, H. (2023). Metodología para el análisis de señales de EEG por mapeo de regiones cerebrales para la salud mental. Tesis de Grado de

Maestría. Universidad Autónoma de Aguascalientes.

[3] Samaniego, M. F. (2023). Eficacia de la estimulación magnética transcraneal en pacientes latinoamericanos con trastorno depresivo. Trabajo de titulación. Universidad Católica de Cuenca.

[4] Zhang, X., Junlei Li, Kechen Hou, Bin Hu, Jian Shen, Jing Pan, Bin Hu. Members IEEE. (2020). EEG- based Depression Detection Using Convolutional Neural Network with Demographic Attention Mechanism.pp. 128-133, doi: 10.1109/EMBC44109.2020.9175956.

[5] Dev, A., Roy, N., Islam, K. Biswas, C., Ahmed, H., Amin, A., Sarker, A., Vaidyanathan, R., Mamun, K. (2022). Exploration of EEG-Based depression biomarkers identification techniques and their applications: A systematic review. in *IEEE Access*, vol. 10, pp. 16756-16781, 2022, doi: 10.1109/ACCESS.2022.3146711.

[6] Song, X., Yan, D., Zhao, I., Yang, L. (2022). LSDD-EEDNey: An efficient end-to-end framework for EEG-based depression detection. *Biomedical Signal Processing and Control*, Volume 75, 2022, 103612, ISSN 16-8094, <https://doi.org/10.1016/j.bspc.2022.103612>. (<https://www.sciencedirect.com/science/article/pii/S146809422001343>).

[7] Zamora, R. D. (X). Reconocimiento de Emociones a partir de la Actividad Eléctrica cerebral con Técnicas de Deep Learning. Tesis de Grado de Ing. Biomédica. Universidad de Valladolid.

[8] Sun, S., Chen H., Shao X., Liu L.(2020). EEG Based depression recognition by combining functional brain network and traditional biomarkers. 2020 IEEE International Conference on Bioinformatics and Biomedicine (BIBM) 97978-1-7281-6215-©2020 IEEE DOI: 10.1109/BIBM49941.2020.9313270.

[9] Sun, S., Li, J., Chen, H., Gong, T., Xiaowei Li. (X). A study of resting-state EEG biomarkers for depression recognition. arXiv:2002.11039 [eess.SP](or arXiv:2002.11039v1 [eess.SP] for this version) <https://doi.org/10.48550/arXiv.2002.11039>.

[10] López D. A.(2019).Trastornos asociados al suicidio y la depresión en adolescente y jóvenes entre 15 y 25 años de edad. Revisión documental. Universidad Cooperativa de Colombia.

[11] Avots, E.; Jermakovs, K.; Bachmann, M.; Päeske, L.; Ozcinar, C.; Anbarjafari, G. Ensemble Approach for Detection of Depression Using EEG Features. *Entropy* 2022, 24, 211. <https://doi.org/10.3390/e24020211>

[12] Li X, La R, Wang Y, Hu B and Zhang X (2020) A Deep Learning Approach for Mild Depression Recognition Based on Functional Connectivity Using Electroencephalography. *Front. Neurosci.* 14:192. doi: 10.3389/fnins.2020.00192

[13] Trambaiolli LR, Biazoli CE. Resting-state global EEG connectivity predicts depression and anxiety severity. *Annu Int Conf IEEE Eng Med Biol Soc.* 2020 Jul;2020:3707-3710. doi: 10.1109/EMBC44109.2020.9176161. PMID: 33018806.

[14] Cukic, M., Stokic M., Radenkovic S., Ljubisavljevic M., Simic S., Savic D. (2019). Nonlinear analysis of EEG complexity in episode and remission phase of recurrent depression. *Int J Methods Psychiatr Res.* 2019;e1816. <https://doi.org/10.1002/mpr.1816>

[15] Kaushik, P., Yang, H., Pratim, P., Van, M.(2023). Comparing resting state and task-based EEG using machine learning to predict vulnerability to depression in a non-clinical population. *Scientific Reports* | (2023) 13:7467 | <https://doi.org/10.1038/s41598-023-34298-2>

[16] Wang B, Kang Y, Huo D, Chen D, Song W, Zhang F. Depression signal correlation identification from different EEG channels based on CNN feature extraction. *Psychiatry Res Neuroimaging.* 2023 Jan;328:111582. doi: 10.1016/j.pscychresns.2022.111582. Epub 2022 Dec 20. PMID: 36565553.

[17] Thoduparambil PP, Dominic A, Varghese SM. EEG-based deep learning model for the automatic detection of clinical depression. *Phys Eng Sci Med.* 2020 Dec;43(4):1349-1360. doi: 10.1007/s13246-020-00938-4. Epub 2020 Oct 22. PMID: 33090373.

[18] Khadidos AO, Alyoubi KH, Mahato S, Khadidos AO, Nandan Mohanty S. Machine Learning and Electroencephalogram Signal based Diagnosis of Dipression. *Neurosci Lett.* 2023 Jul 13;809:137313. doi: 10.1016/j.neulet.2023.137313. Epub 2023 May 29. PMID: 37257682.

[19] Chung KH, Chang YS, Yen WT, Lin L, Abimannan S. Depression assessment using integrated multi-featured EEG bands deep neural network models: Leveraging ensemble learning techniques. *Comput Struct Biotechnol J.* 2024 Apr 1;23:1450-1468. doi: 10.1016/j.csbj.2024.03.022. PMID: 38623563; PMCID: PMC11016871.

[20] Xuexiao Shao, Ming Ying, Jing Zhu, Xiaowei Li, Bin Hu. Achieving EEG-based depression recognition using Decentralized-Centralized structure, *Biomedical Signal Processing and Control*, Volume 95, Part A, 2024, 106402, ISSN 1746-8094, <https://doi.org/10.1016/j.bspc.2024.106402>. (<https://www.sciencedirect.com/science/article/pii/S1746809424004609>)

[21] Umezaki FBH, Sousa YP, Pereira TD, Fraga FJ. Diagnosis support of major depressive disorder using event-related potentials during affective priming tasks. *Psychiatry Res Neuroimaging.* 2024 Jul;341:111827. doi: 10.1016/j.pscychresns.2024.111827. Epub 2024 May 12.

PMID: 38788296.

**[22]** Ay B, Yildirim O, Talo M, Baloglu UB, Aydin G, Puthankattil SD, Acharya UR. Automated Depression Detection Using Deep Representation and Sequence Learning with EEG Signals. *J Med Syst.* 2019 May 28;43(7):205. doi: 10.1007/s10916-019-1345-y. PMID: 31139932.

**[23]** Mahato, S., Goyal, N., Ram, D. *et al.* Detection of Depression and Scaling of Severity Using Six Channel EEG Data. *J Med Syst* 44, 118 (2020). <https://doi.org/10.1007/s10916-020-01573-y>

**[24]** Geetanjali Sharma, Abhishek Parashar, Amit M. Joshi, DepHNN: A novel hybrid neural network for electroencephalogram (EEG)-based screening of depression, *Biomedical Signal Processing and Control*, Volume 66, 2021, 102393, ISSN 1746-8094, <https://doi.org/10.1016/j.bspc.2020.102393> (<http://www.sciencedirect.com/science/article/pii/S1746809420304997>)

**[25]** A. Rafiei, R. Zahedifar, C. Sitaula and F. Marzbanrad, "Automated Detection of Major Depressive Disorder With EEG Signals: A Time Series Classification Using Deep Learning," in *IEEE Access*, vol. 10, pp. 73804-73817, 2022, doi: 10.1109/ACCESS.2022.3190502.

**[26]** Duan L, Duan H, Qiao Y, Sha S, Qi S, Zhang X, Huang J, Huang X and Wang C (2020) Machine Learning Approaches for MDD Detection and Emotion Decoding Using EEG Signals. *Front. Hum. Neurosci.* 14:284. doi: 10.3389/fnhum.2020.00284

**[27]** Liu, W.; Jia, K.; Wang, Z.; Ma, Z. A Depression Prediction Algorithm Based on Spatiotemporal Feature of EEG Signal. *Brain Sci.* 2022, 12, 630. <https://doi.org/10.3390/brainsci12050630>

**[28]** D. M. Khan, K. Masroor, M. F. M. Jailani, N. Yahya, M. Z. Yusoff and S. M. Khan, "Development of Wavelet Coherence EEG as a Biomarker for Diagnosis of Major Depressive Disorder," in *IEEE Sensors Journal*, vol. 22, no. 5, pp. 4315-4325, 1 March1, 2022, doi: 10.1109/JSEN.2022.3143176.

**[29]** Khan S, Umar Saeed SM, Frnda J, Arsalan A, Amin R, Gantassi R, et al. (2024) A machine learning based depression screening framework using temporal domain features of the electroencephalography signals. *PLoS ONE* 19(3):e0299127. <https://doi.org/10.1371/journal.pone.0299127>

**[30]** Thakare A, Bhende M, Deb N, Degadwala S, Pant B, Kumar YP. Classification of Bioinformatics EEG Data Signals to Identify Depressed Brain State Using CNN Model. *Biomed Res Int.* 2022 Apr 13;2022:5214195. doi: 10.1155/2022/5214195. Retraction in: *Biomed Res Int.*

2024 Mar 20;2024:9805304. doi: 10.1155/2024/9805304. PMID: 35463968; PMCID: PMC9020967.

**[31]** C. Greco, O. Matarazzo, G. Cordasco, A. Vinciarelli, Z. Callejas and A. Esposito, "Discriminative Power of EEG-Based Biomarkers in Major Depressive Disorder: A Systematic Review," in *IEEE Access*, vol. 9, pp. 112850-112870, 2021, doi: 10.1109/ACCESS.2021.3103047.

**[32]** T. Habiram Obispo-Bustillos a , Nimrod González-Franco , Juan Gabriel González-Serna, Dante Mújica-Vargas d , Noé Alejandro Castro-Sánchez. (2023). Tendencias y perspectivas en la detección de depresión mediante el análisis de señales Electroencefalográficas (EEG): una Revisión Sistemática de la Literatura. *Publicación semestral*, Vol. 11, No. 22 (2023) 1-11 <https://repository.uaeh.edu.mx/revistas/index.php/xikua/issue/archive>

**[33]** Kaushik, P., Yang, H., Roy, P.P. *et al.* Comparing resting state and task-based EEG using machine learning to predict vulnerability to depression in a non-clinical population. *Sci Rep* 13, 7467 (2023). <https://doi.org/10.1038/s41598-023-34298-2>

**[34]** Quintero, J. (2021). Procesamiento electrocortical de la repetición de escenas emocionales en estrés, ansiedad y depresión. *Master en Psicología*. Universidad de La Laguna.

**[35]** Schiller MJ (2019) Quantitative Electroencephalography in Guiding Treatment of Major Depression. *Front. Psychiatry* 9:779. doi: 10.3389/fpsyt.2018.00779

**[36]** Liu S, Liu X, Yan D, Chen S, Liu Y, Hao X, Ou W, Huang Z, Su F, He F, Ming D. Alterations in Patients With First-Episode Depression in the Eyes-Open and Eyes-Closed Conditions: A Resting-State EEG Study. *IEEE Trans Neural Syst Rehabil Eng.* 2022;30:1019-1029. doi: 10.1109/TNSRE.2022.3166824. Epub 2022 Apr 21. PMID: 35412986.

**[37]** ZonalT. (2016). Avances en la caracterización del trastorno depresivo mayor y la conectividad funcional neuronal - Biotech Spain. *Biotech-Spain.com*. <https://biotech-spain.com/es/articles/avances-en-la-caracterizaci-n-del-trastorno-depresivo-mayor-y-la-conectividad-funcional-neuronal-/#:~:text=Del%20an%C3%A1lisis%20de%20la%20conectividad,estados%20reflexivos%20y%20de%20pensamiento>

**[38]** Sereno, L., & Camelo, S. (2020). Efecto de las experiencias adversas durante la niñez sobre la actividad electroencefalográfica en reposo: Una revisión sistemática. *Psychologia*, 14(2), 81-94. <https://doi.org/>



10.21500/19002386.4888

**[39]** Wang X-Q, Wang D-Q, Bao Y-P, Liu J-J, Chen J, Wu S-W, Luk H-N, Yu L, Sun W, Yang Y, Wang X-H, Lu L, Deng J-H and Li S-X (2021) Preliminary Study on Changes of Sleep EEG Power and Plasma Melatonin in Male Patients With Major Depressive Disorder After 8 Weeks Treatment. *Front. Psychiatry* 12:736318. doi: 10.3389/fpsy.2021.736318

**[40]** Huang SS, Yu YH, Chen HH, Hung CC, Wang YT, Chang CH, Peng SJ, Kuo PH. Functional connectivity analysis on electroencephalography signals reveals potential biomarkers for treatment response in major depression. *BMC Psychiatry*. 2023 Aug 1;23(1):554. doi: 10.1186/s12888-023-04958-8. PMID: 37528355; PMCID: PMC10394892.

**[41]** Wang J, Liu Q, Tian F, Zhou S, Parra MA, Wang H and Yu X (2022) Disrupted Spatiotemporal Complexity of Resting-State Electroencephalogram Dynamics Is Associated With Adaptive and Maladaptive Rumination in Major Depressive Disorder. *Front. Neurosci.* 16:829755. doi: 10.3389/fnins.2022.829755

**[42]** Wolff A, de la Salle S, Sorgini A, Lynn E, Blier P, Knott V and Northoff G (2019) Atypical Temporal Dynamics of Resting State Shapes, Stimulus-Evoked Activity in Depression—An EEG Study on Rest–Stimulus Interaction. *Front. Psychiatry* 10:719. doi: 10.3389/fpsy.2019.00719

**[43]** Hill, A.T., Hadas, I., Zomorodi, R. *et al.* Modulation of functional network properties in major depressive disorder following electroconvulsive therapy (ECT): a resting-state EEG analysis. *Sci Rep* 10, 17057 (2020). <https://doi.org/10.1038/s41598-020-74103-y>

**[44]** Mazza F, Guet-McCreight A, Valiante TA, Griffiths JD, Hay E (2023) In-silico EEG biomarkers of reduced inhibition in human cortical microcircuits in depression. *PLoS Comput Biol* 19(4): e1010986. <https://doi.org/10.1371/journal.pcbi.1010986>

**[45]** Debby Klooster, Helena Voetterl, Chris Baeken, and Martijn Arns (2019). Evaluating Robustness of Brain Stimulation Biomarkers for Depression: A Systematic Review of Magnetic Resonance Imaging and Electroencephalography Studies. ISSN: 0006-3223 *Biological Psychiatry* March 15, 2024; 95:553–563 [www.sobp.org/journal](http://www.sobp.org/journal) <https://doi.org/10.1016/j.biopsych.2023.09.009>

**[46]** Zuchowicz U, Wozniak-Kwasniewska A, Szekely D, Olejarczyk E and David O (2019) EEG Phase Synchronization in Persons With Depression Subjected to Transcranial Magnetic Stimulation. *Front. Neurosci.* 12:1037. doi: 10.3389/fnins.2018.01037

**[47]** Cavanagh, J. F., Bismark, A. W., Frank, M. J., & Allen, J.

J. B. (2019). Multiple dissociations between comorbid depression and anxiety on reward and punishment processing: Evidence from computationally informed EEG. *Computational Psychiatry*, 3, 1–17. [https://doi.org/10.1162/cpsy\\_a\\_00024](https://doi.org/10.1162/cpsy_a_00024) DOI: [https://doi.org/10.1162/cpsy\\_a\\_00024](https://doi.org/10.1162/cpsy_a_00024)

**[48]** Yi L, Xie G, Li Z, Li X, Zhang Y, Wu K, Shao G, Lv B, Jing H, Zhang C, Liang W, Sun J, Hao Z and Liang J (2023) Automatic depression diagnosis through hybrid EEG and near-infrared spectroscopy features using support vector machine. *Front. Neurosci.* 17:1205931. doi: 10.3389/fnins.2023.1205931

**[49]** Zhu, G.; Qiu, T.; Ding, Y.; Gao, S.; Zhao, N.; Liu, F.; Zhou, X.; Gururajan, R. Detecting Depression Using Single-Channel EEG and Graph Methods. *Mathematics* 2022, 10, 4177. <https://doi.org/10.3390/math10224177> Academic Editor: Takashi Yamauchi

**[50]** Damborská, A., Honzírková, E., Barteček, R. *et al.* Altered directed functional connectivity of the right amygdala in depression: high-density EEG study. *Sci Rep* 10, 4398 (2020). <https://doi.org/10.1038/s41598-020-61264-z>

**[51]** Shi, Q., Liu, A., Chen, R., Shen, J., Zhao, Q., & Hu, B. (2020). Depression detection using resting state three-channel EEG signal. *arXiv preprint arXiv:2002.09175*.

**[52]** Abdullah, S., Abosuliman, S.S. Analyzing of optimal classifier selection for EEG signals of depression patients based on intelligent fuzzy decision support systems. *Sci Rep* 13, 11425 (2023). <https://doi.org/10.1038/s41598-023-36095-3>

**[53]** Shamilov Vladimir Malakhonovich, Prostyakova Natalia Turchaninova, Sharapova Dilyuza Nematillayevna, Shernazarov Farrukh. (2023). DISORDERS OF DECISION-MAKING IN THE CASE OF DEPRESSION: CLINICAL EVALUATION AND CORRELATION WITH EEG INDICATORS. <https://doi.org/10.5281/zenodo.10336711>

**[54]** W. Liu, J. Song, Z. Wang and H. Cheng, "Comparison of Performance of EEG-Based Depression classification," 2022 2nd International Conference on Frontiers of Electronics, Information and Computation Technologies (ICFEICT), Wuhan, China, 2022, pp. 125-130, doi: 10.1109/ICFEICT57213.2022.00030

**[55]** S. Hashempour, R. Boostani, M. Mohammadi and S. Sanei, "Continuous Scoring of Depression From EEG Signals via a Hybrid of Convolutional Neural Networks," in *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 30, pp. 176-183, 2022, doi: 10.1109/TNSRE.2022.3143162.

**[56]** Peng D, Liu W, Luo Y, Mao Z, Zheng WL, Lu BL. Deep Depression Detection with Resting-State and

Cognitive-Task EEG. Annu Int Conf IEEE Eng Med Biol Soc. 2023 Jul;2023:1-4. doi: 10.1109/EMBC40787.2023.10340667. PMID: 38083722.

[57] P. Naregalkar, A. A. Shinde and M. V. Patil, "Depression Diagnosis Using Linear Features Based on EEG Signals," 2023 International Conference on Computational Intelligence, Networks and Security (ICCINS), Mylavaram, India, 2023, pp. 1-6, doi: 10.1109/ICCINS58907.2023.10450119.

[58] Shen J, Zhang Y, Liang H, Zhao Z, Zhu K, Qian K, Dong Q, Zhang X, Hu B. Depression Recognition From EEG Signals Using an Adaptive Channel Fusion Method via Improved Focal Loss. *IEEE J Biomed Health Inform.* 2023 Jul;27(7):3234-3245. doi: 10.1109/JBHI.2023.3265805. Epub 2023 Jun 30. PMID: 37037251.

[59] Thulasi, K., Balakrishnan, S., Suan, Y. J., Qing, Y. X., Malarvili, M. B., Murugesan, R. K., & Devandran, P. (2023, September). Detecting Mild Depression from EEG Signal in a Non-Clinical Environment Using Machine Learning Technique. In *2023 IEEE 2nd National Biomedical Engineering Conference (NBEC)* (pp. 100-105). IEEE

[60] F. Chen et al., "Different Sub-bands Assessment of the Resting-state Prefrontal EEG in Depression Patients," 2022 International Conference on Sensing, Measurement & Data Analytics in the era of Artificial Intelligence (ICSMD), Harbin, China, 2022, pp. 1-6, doi: 10.1109/ICSMD57530.2022.10058461

[61] J. Su and T. Song, "EEG-Based Depression Recognition Using Time-Frequency Convolutional Networks," 2023 16th International Congress on Image and Signal Processing, BioMedical Engineering and Informatics (CISP-BMEI), Taizhou, China, 2023, pp. 1-5, doi: 10.1109/CISP-BMEI60920.2023.10373260.

[62] L. Minkowski, K. V. Mai and D. Gurve, "Feature Extraction to Identify Depression and Anxiety Based on EEG," 2021 43rd Annual International Conference of the IEEE Engineering in Medicine & Biology Society (EMBC), Mexico, 2021, pp. 6322-6325, doi: 10.1109/EMBC46164.2021.9630821.

[63] Qayyum A, Razzak I, Tanveer M, Mazher M, Alhaqbani B. High-Density Electroencephalography and Speech Signal Based Deep Framework for Clinical Depression Diagnosis. *IEEE/ACM Trans Comput Biol Bioinform.* 2023 Jul-Aug;20(4):2587-2597. doi: 10.1109/TCBB.2023.3257175. Epub 2023 Aug 9. PMID: 37028339.

[64] Shen, J., Zhang, X., Huang, X., Wu, M., Gao, J., Lu, D., ... & Hu, B. (2020). An optimal channel selection for EEG-based depression detection via kernel-target alignment. *IEEE Journal of Biomedical and Health*

*Informatics*, 25(7), 2545-2556.

[65] Parisa Raouf, Vahid Shalchyan, Reza Rostami, Investigation of the impact of cross-frequency coupling on the assessment of depression severity through the analysis of resting state EEG signals, *Biomedical Signal Processing and Control*, Volume 95, Part B, 2024, 106392, ISSN 1746-8094, <https://doi.org/10.1016/j.bspc.2024.106392>. (<https://www.sciencedirect.com/science/article/pii/S1746809424004506>)

[66] Chung, K. H., Chang, Y. S., Yen, W. T., Lin, L., & Abimannan, S. (2024). Depression assessment using integrated multi-featured EEG bands deep neural network models: Leveraging ensemble learning techniques. *Computational and Structural Biotechnology Journal*, 23, 1450-1468.

[67] Yang, L., Wang, Y., Zhu, X., Yang, X., & Zheng, C. (2023). A gated temporal-separable attention network for EEG-based depression recognition. *Computers in Biology and Medicine*, 157, 106782.

[68] Yang, J., Zhang, Z., Fu, Z., Li, B., Xiong, P., & Liu, X. (2023). Cross-subject classification of depression by using multiparadigm EEG feature fusion. *Computer Methods and Programs in Biomedicine*, 233, 107360.

[69] Zhang, Y., Wang, K., Wei, Y., Guo, X., Wen, J., & Luo, Y. (2022). Minimal EEG channel selection for depression detection with connectivity features during sleep. *Computers in Biology and Medicine*, 147, 105690.

[70] Pöld, T., Päeske, L., Hinrikus, H., Lass, J., & Bachmann, M. (2023). Temporal stability and correlation of EEG markers and depression questionnaires scores in healthy people. *Scientific Reports*, 13(1), 21996.